Федеральное государственное автономное образовательное учреждение высшего образования
«Национальный исследовательский университет ИТМО»
Факультет инфокоммуникационных технологий

ОТЧЕТ

по лабораторной работе №6
«AI-детектив»
по дисциплине «Автоматическая обработка текстов»

Выполнили студенты группы К3440:
Мещеряков Даниил Павлович, ИСУ 409130
Соболь Владимир Вячеславович, ИСУ 409594

Санкт-Петербург
2026

1. Досье и эталоны

Сюжет вымышленный: закрытая сборка игры «Северный Прилив» студии «Тихий Бор» утекла на форум «Бухта Бит». Сначала в `data/truth.md` зафиксирована истинная последовательность событий, затем написаны 10 документов на 5641 слово, каждый раскрывает только часть событий:

- описание инцидента с временной шкалой;
- три сообщения участников;
- фрагмент чата;
- выгрузка журналов (хранилище, реестр водяных знаков, проходная, телефония);
- регламент;
- распоряжение-исключение;
- два нерелевантных отчета на близкие темы.

Шкала вложена в описание инцидента, иначе обязательный состав не помещается в 10 документов.

Выделено 40 утверждений: 31 direct, 4 disputed, 3 reported и 2 inferred. Evidence каждого утверждения дословно и ровно один раз входит в свой документ, это проверяет `make_data.py`. Вопросов 12, по два каждого типа. Эталонные статусы: 5 entailed, 4 contradicted, 1 both, 2 insufficient.

В досье заложены ловушки:

- форум показывает время в UTC, а журналы студии ведутся по Москве;
- ключ технически открывал полный архив, хотя распоряжение разрешало только файлы локализации;
- свидетель противоречит журналу проходной;
- о содержании звонка есть две версии, а записи нет.

До запуска модели эталоны вслепую проверил второй экземпляр ассистента: 12 статусов совпали, пять найденных несостыковок исправлены. После прогона эталоны проверили оба участника, правок не потребовалось.

2. Стенд и режимы

Код, данные и все ответы модели лежат в репозитории github.com/Toneryy/aot-2026, папка labs/lab6. Модель: qwen2.5:7b через Ollama, temperature 0, seed 42, окно 20480 токенов, ответ по JSON-схеме Pydantic. Промпт и параметры одинаковы во всех режимах.

Ответ модели проверяется:

- ответ соответствует схеме;
- все идентификаторы существуют в claims.jsonl;
- при both заполнены counterevidence;

- при insufficient answer равен null и в ответе нет времени или кодов, которых нет в контексте.

При ошибке разрешен один повторный запрос. В основном прогоне он не понадобился ни разу.

- **A:** все документы в фиксированном порядке. После каждого evidence стоит метка [Cxx], чтобы модель могла ссылаться на утверждения. Контекст занимает 15,9 тыс. токенов.
- **B:** BM25 (псевдооснова 5 символов) по текстам утверждений, top-15 плоским списком.
- **C:** те же 15 утверждений, сгруппированные по p-adic ветвям, внутри ветви по времени факта.

p-adic путь [a0, a1, a2]:

- a0, тип источника: журнал или документ, свидетельство, правило или интерпретация;
- a1, статус: установленный факт, сообщение, спорное или исключение;
- a2, время: до, во время, после события или неизвестно.

Код x = a0 + 3a1 + 9a2. Расстояние равно 3^(-k), где k число совпадающих начальных уровней. Тесты сверяют его с 3-адическим нормированием разности кодов и проверяют ультраметрическое неравенство на всех тройках путей.

Стресс-тесты:

- перестановка документов с random_state=42 (в режиме B переставляется и список утверждений);
- удаление необходимой посылки для multi-hop и временных вопросов, ожидается insufficient;
- несовместимое утверждение от другого источника для всех 12 вопросов, ожидается both.

Каждый вариант меняет один фактор. Всего 120 запросов.

3. Результаты

Метрика	A	B	C
Точность статуса	0,50	0,50	0,50
Evidence P / R / F1	0,27 / 0,29 / 0,26	0,37 / 0,44 / 0,37	0,46 / 0,53 / 0,47
Полнота counterevidence	0	0	0,13
both: верно / предсказано / ожидалось (все 40 запусков)	0 / 0 / 14	0 / 0 / 14	5 / 7 / 14
insufficient: верно / предсказано / ожидалось	3 / 5 / 8	3 / 4 / 8	1 / 1 / 8
Уверенный ответ (0,7 и выше) при нехватке данных	5 из 8	5 из 8	5 из 8
Средняя уверенность / ECE	0,92 / 0,61	0,95 / 0,64	0,95 / 0,56
Токены промпта	15 865	1 311	1 500
Время, медиана (холодный запрос)	8,4 с (85 с)	8,1 с	8,6 с

Медиана времени в режиме A низкая из-за кэша префикса в Ollama: документы одинаковы, поэтому заново считается только вопрос. Холодный запрос полного контекста идет 85 секунд.

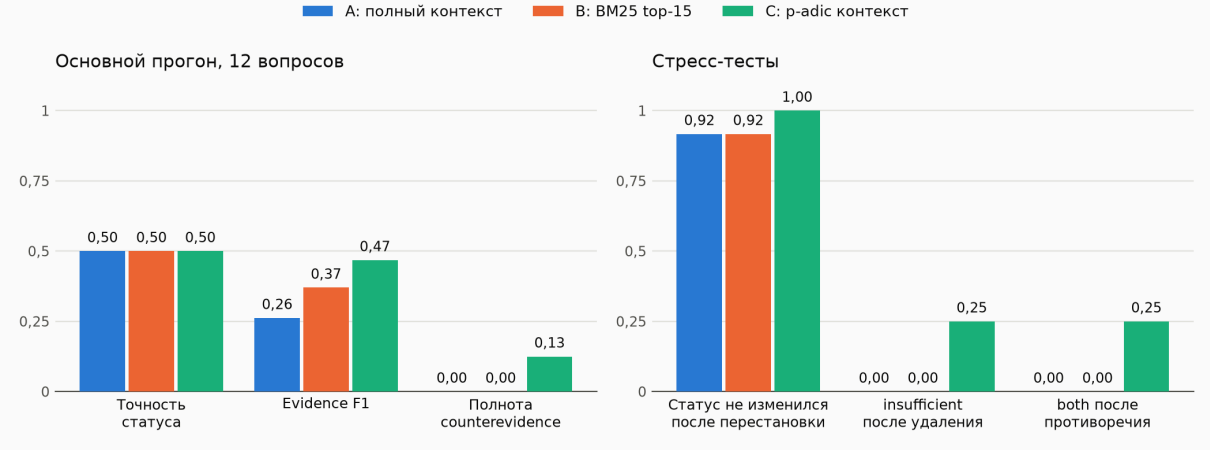


Рисунок 1. Метрики основного прогона и стресс-тестов

Стресс-тест	A	B	C
Статус изменился после перестановки	1 из 12	1 из 12	0 из 12
Совпадение evidence с исходным (Жаккар)	0,47	0,63	1,00
insufficient после удаления посылки	0 из 4	0 из 4	1 из 4
both после противоречия, попавшего в контекст	0 из 12	0 из 10	3 из 10

Все 18 ошибок основного прогона разобраны вручную (`results/error_analysis.csv`):

Причина	A	B	C
Время не переведено из UTC	Q06	Q06	Q06
Свидетель принят вместо журнала	Q09	Q09	Q09
Правило применено без исключения	Q08	Q08	Q08
Догадка или выдуманный факт	Q04	Q04, Q11	Q04
Статус не согласован с объяснением, конфликт не замечен	Q10	Q10	Q11
Норма вместо факта или both вместо insufficient	Q12	нет	Q12
Среди них нужного утверждения нет в top-15	не применимо	3	4

4. Ответы на вопросы отчета

1. **Улучшает ли retrieval результат по сравнению с полным текстом?** По статусу нет: 6 из 12 во всех режимах. По доказательствам да: evidence F1 растет с 0,26 до 0,37 при контексте в 12 раз короче, а в режиме A модель часто перечисляет подряд соседние строки журнала. Слабое место в поиске: полнота эталонных утверждений в top-15 равна 0,79. BM25 не находит строку реестра водяных знаков и пункт о тихом периоде, потому что в них нет слов из вопроса. На Q04 и Q08 ошибка B и C начинается именно с поиска.
2. **Улучшает ли p-adic группировка распознавание противоречий?** Да, но частично. both распознает только режим C: Q10 в основном прогоне и 3 из 10 добавленных противоречий (камера против проходной, новый свидетель звонка, коллега против Марка). Режимы A и B не распознали ни одного. Помогает то, что спорные утверждения собраны в отдельные ветви с подписью «спорное». Расхождения в технических данных (два журнала загрузки, две экспертизы водяного знака, два времени регистрации аккаунта) модель не заметила ни в одном режиме.
3. **Отличает ли модель insufficient от правдоподобной догадки?** Плохо. В 5 из 8 случаев с нехваткой данных она дала уверенный entailed или contradicted. Примеры: в режиме B владельцем аккаунта назван Тимур с уверенностью 0,95; в режиме A ответ звучит «не мог скачать намеренно, потому что регламент это запрещает». Режим C почти не отвечает insufficient (1 из 8) и подменяет нехватку данных на both.
4. **Меняется ли ответ после перестановки документов?** В режимах A и B статус изменился по одному разу, оба раза с неверного на верный. Это неустойчивость, а не улучшение. Evidence совпадает с исходным только на 47% и 63%. Режим C от порядка не зависит по построению: контекст после перестановки тот же, и ответы совпали полностью.
5. **Как модель реагирует на удаление необходимой посылки?** Почти не замечает. В режимах A и B все 8 ответов остались entailed с прежней уверенностью, в C insufficient появился один раз из четырех (Q06). Модель достраивает посылку: без водяного знака связывает утечку с ключом RK-02 по совпадению времени, а без строки об отказе в 19:26 подставляет успешное скачивание в 18:31.
6. **Соответствует ли confidence фактической точности?** Нет. От 32 до 36 ответов из 40 в каждом режиме имеют уверенность 0,95 и выше, а их точность 0,28-0,31; ECE от

0,56 до 0,64. Сигнал есть только у редких ответов с уверенностью ниже 0,8: в режиме C оба такие ответа верные.

7. **В каких случаях p-adic структура помогает, а в каких мешает?** Помогает, когда нужно увидеть спор источников разных типов и сохранить ответ при перестановке. У режима C лучшая привязка доказательств (F1 0,47) и единственные распознанные both. Мешает там, где правило, исключение и вывод попадают в разные ветви. В Q08 тихий период лежит в ветви выводов [2,0,1], окно ключа в ветви исключений [2,2,0], и модель ответила по ключу. Подпись «спорное» провоцирует both: 2 из 7 предсказаний both ошибочны.

5. Порядок уровней p-adic пути

Первый уровень задает самое крупное деление: утверждения с разным типом источника всегда находятся на расстоянии 1. Тип источника поставлен выше времени, потому что для расследования главное различие в надежности: журнал, свидетель или норма. Время важно, но относится к конкретному утверждению, а надежность определяет, можно ли ему верить.

Если поставить время первым, журнал проходной и показания Ольги окажутся в одной ветви «во время события». Спор источников будет выглядеть как соседние факты. Зато ветви станут хронологией, и это могло бы помочь временным вопросам, на которых ошиблись все режимы. Если поставить первым статус, все спорное соберется вместе независимо от источника. Это удобно для both, но смешает журнал и свидетеля с одинаковым статусом. Другой порядок мы не проверяли, это гипотеза.

6. Дополнительная проверка: порядок полей ответа

Схема Ollama заставляет модель назвать статус раньше доказательств. Чтобы проверить, не отсюда ли уклон в «да», мы повторили основной прогон на тех же 36 запросах, поставив в схеме доказательства и объяснение перед статусом. Точность упала до 0,42, 0,33 и 0,33. Уклон сменил форму: в B и C модель стала отвечать both в 12 случаях из 24. Evidence F1 немного вырос (B 0,44, C 0,51). Значит, дело не в порядке полей: модель плохо выбирает логический статус как таковой.

7. Выводы и ограничения

- Главные ошибки модели лежат не в поиске, а в логическом статусе. В основном прогоне 31 ответ из 36 это entailed: модель соглашается с вопросом, не переводит время и доверяет свидетелю больше, чем журналу.
- Retrieval сокращает контекст в 10-12 раз при той же точности и лучших доказательствах. p-adic упаковка дает лучшую привязку доказательств и распознавание споров, но не исправляет ошибки со временем и исключениями.
- Ограничения: 12 вопросов и одна модель на 7 млрд параметров. Разница в один вопрос дает 8 процентных пунктов, поэтому различия в точности статуса статистически ненадежны. Выводы относятся только к этой модели и этому досье.

8. Вклад участников

- **Соболь:** досье, утверждения, вопросы и эталоны, варианты стресс-тестов, промпт, вызов модели и проверка ответа, разбор ошибок.
- **Мещеряков:** BM25, p-adic модуль, сборка контекста, стресс-тесты, метрики, Streamlit-стенд, тесты.
- **Вместе:** проверка эталонов, выводы и отчет.

Подробности в `CONTRIBUTIONS.md`, эпизоды работы с ИИ в `AI_LOG.md`.